# RELATÓRIO — PROBLEMA 3

## Clusterização: “O Perfil do Consumidor”

**Trabalho Prático AV1 — Machine Learning**

Integrante: Erick William, Gean Carlos, Liedson Araujo e Luiz Henrique

## 1. Introdução

A segmentação de clientes permite identificar grupos com comportamentos semelhantes e apoiar decisões de marketing. Neste problema, foi utilizado aprendizado não supervisionado para agrupar clientes de um shopping a partir de duas variáveis: renda anual e pontuação de gastos (Spending Score). Como os dados não possuem rótulos de segmento previamente definidos, o algoritmo K-Means forma os grupos e a interpretação comercial é realizada posteriormente.

## 2. Objetivo

Aplicar o algoritmo K-Means para segmentar os clientes, padronizar as variáveis utilizadas, selecionar o número de grupos com apoio do Método do Cotovelo e do coeficiente de silhueta, visualizar os resultados e propor perfis e ações de marketing.

## 3. Base de dados e preparação

O arquivo Mall_Customers.csv contém 200 registros e cinco colunas: CustomerID, Gender, Age, Annual Income (k$) e Spending Score (1-100). A inspeção da base não identificou valores ausentes nem linhas completamente duplicadas. A base foi mantida sem exclusões, e somente Annual Income (k$) e Spending Score (1-100) foram utilizadas no treinamento.

CustomerID e Gender não entraram no modelo. Age também foi mantida fora do treinamento; foi usada apenas para ajudar a caracterizar os segmentos após a clusterização. Assim, os agrupamentos refletem renda e pontuação de gastos, não idade ou gênero.

## 4. Questão 1 — Escalonamento das variáveis

O K-Means utiliza distâncias euclidianas para agrupar observações. Se as variáveis estiverem em escalas muito diferentes, aquela com valores numericamente maiores pode dominar a distância. Para reduzir esse risco, foi aplicado StandardScaler, que transforma cada variável em um escore z: $z = (x - \mu) / \sigma$, em que $\mu$ é a média e $\sigma$ é o desvio padrão.

Neste conjunto, a renda anual varia de 15 a 137 (em milhares de dólares) e o Spending Score varia de 1 a 99. As dispersões das duas variáveis são semelhantes, portanto o efeito prático do escalonamento tende a ser menor do que seria em variáveis com escalas muito distintas. Ainda assim, a padronização torna o procedimento consistente e evita que a escala original seja o critério dominante.

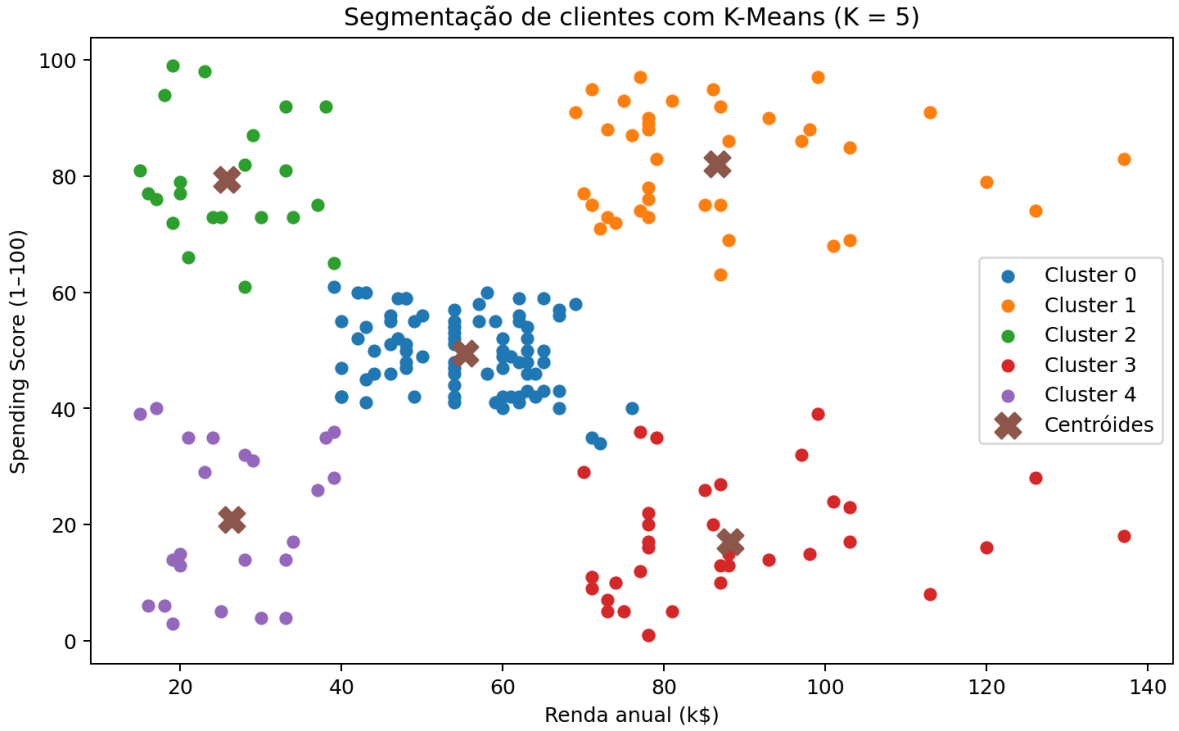
## 5. Questão 2 — Escolha do número de clusters

O Método do Cotovelo foi aplicado a valores de K entre 1 e 10, observando-se a inércia — soma das distâncias quadráticas dos pontos aos centróides. A inércia diminui à medida que K aumenta; busca-se o ponto em que a redução passa a ser menos expressiva. A análise do notebook selecionou K = 5.

O coeficiente de silhueta também foi calculado como apoio. Para K = 5, o valor foi 0.555; para K = 4, 0.494; e para K = 6, 0.540. O maior valor entre os K avaliados ocorreu em K = 5, apoiando a escolha de cinco grupos.

## 6. Questão 3 — Treinamento e visualização

O modelo K-Means foi treinado com K = 5, random_state = 42 e n_init = 10. Cada ponto do gráfico representa um cliente, posicionado conforme renda anual e Spending Score; as cores indicam o cluster e os marcadores X mostram os centróides. A execução reproduzida com o CSV fornecido distribuiu os 200 clientes em cinco grupos.




| Cluster | Clientes | Renda média (k$) | Gasto médio | Idade média |
|---|---|---|---|---|
| **0** | 81 | 55.3 | 49.5 | 42.7 |
| **1** | 39 | 86.5 | 82.1 | 32.7 |
| **2** | 22 | 25.7 | 79.4 | 25.3 |
| **3** | 35 | 88.2 | 17.1 | 41.1 |
| **4** | 23 | 26.3 | 20.9 | 45.2 |

## 7. Questão 4 — Interpretação de negócios

O algoritmo identifica grupos matemáticos, mas não atribui significado comercial a eles. Os nomes abaixo são interpretações humanas baseadas na posição dos centróides em relação às médias gerais de renda e gastos.

| Perfil | Características médias | Interpretação | Ação sugerida |
|---|---|---|---|
| **Os Moderados** | Renda: 55.3 k$<br>Gastos: 49.5<br>Clientes: 81 | Renda e pontuação de gastos próximas dos valores médios. | Promoções sazonais, combos e ações para aumentar a recorrência. |
| **Os VIPs** | Renda: 86.5 k$<br>Gastos: 82.1<br>Clientes: 39 | Renda alta e pontuação de gastos alta. | Programa de fidelidade, atendimento exclusivo e acesso antecipado a lançamentos. |
| **Os Impulsivos** | Renda: 25.7 k$<br>Gastos: 79.4<br>Clientes: 22 | Renda baixa, mas pontuação de gastos alta. | Cupons, ofertas oportunas e campanhas de oportunidade. |
| **Os Econômicos** | Renda: 88.2 k$<br>Gastos: 17.1<br>Clientes: 35 | Renda alta, mas pontuação de gastos baixa. | Ofertas exclusivas e experiências premium para estimular o consumo. |
| **Os Contidos** | Renda: 26.3 k$<br>Gastos: 20.9 | Renda baixa e pontuação de | Liquidações, descontos progressivos e cupons de baixo |

| | | | |
|---|---|---|---|
| | Clientes: 23 | gastos baixa. | valor. |

Os VIPs podem receber benefícios de fidelidade; Os Econômicos podem ser estimulados com ofertas personalizadas; Os Moderados podem responder a campanhas de recorrência; Os Impulsivos podem ser alcançados por ofertas oportunas; e Os Contidos podem receber comunicações focadas em preço e descontos. Essas ações são hipóteses de marketing a validar com resultados reais de campanhas, não garantias de comportamento.

A idade média é uma informação complementar: ela não participou da clusterização. Na execução reproduzida, os Impulsivos apresentaram idade média de 25.3 anos, enquanto Os Contidos apresentaram 45.2 anos.

## 8. Limitações

A análise considera apenas renda anual e Spending Score, portanto não explica todos os fatores que influenciam o consumo. Os nomes comerciais são interpretações simplificadas e não rótulos objetivos fornecidos pela base. O K-Means depende da escolha de K e tende a funcionar melhor em grupos compactos; por isso, os segmentos devem ser avaliados junto ao contexto de negócio.

## 9. Conclusão

O experimento aplicou padronização, seleção de K e K-Means para organizar os 200 clientes em cinco segmentos com perfis distintos. O Método do Cotovelo, apoiado pelo coeficiente de silhueta de 0,555 para K = 5, fundamentou a escolha do número de grupos. A interpretação comercial transforma os resultados técnicos em hipóteses de campanhas direcionadas, que podem ser testadas e aprimoradas com dados de desempenho.

## Referências

SCIKIT-LEARN. KMeans. Documentação oficial. https://scikit-learn.org/stable/modules/generated/sklearn.cluster.KMeans.html

SCIKIT-LEARN. StandardScaler. Documentação oficial. https://scikit-learn.org/stable/modules/generated/sklearn.preprocessing.StandardScaler.html

SCIKIT-LEARN. silhouette_score. Documentação oficial. https://scikit-learn.org/stable/modules/generated/sklearn.metrics.silhouette_score.html