Problema 4 — Clusterização Musical: Criando a Playlist Perfeita

Trabalho Prático AV1 — Machine Learning

Equipe: Erick William, Gean Carlos, Liedson Araujo e Luiz Henrique

1. Introdução

Aplicativos de streaming podem utilizar técnicas de aprendizado de máquina para organizar músicas em playlists de acordo com características sonoras. Neste problema, o objetivo foi agrupar faixas com propriedades acústicas semelhantes, sem utilizar o gênero musical cadastrado como critério de treinamento. A atividade foi conduzida como um problema de aprendizado não supervisionado, no qual os grupos são identificados a partir dos padrões presentes nos dados, sem rótulos prévios.

2. Objetivo

Aplicar o algoritmo K-Means para formar cinco grupos de músicas com base em características musicais, analisar a relação entre energia (energy) e acústica (acousticness) e avaliar qualitativamente se cinco faixas pertencentes ao mesmo cluster poderiam fazer sentido em uma playlist.

3. Base de dados e limpeza

O arquivo original continha 114.000 registros e 21 colunas. A inspeção inicial identificou 89.741 identificadores de faixa distintos, sem IDs ausentes e sem linhas completamente duplicadas. Também foi encontrado um registro sem nome da música, artista e álbum. A limpeza removeu a coluna de índice exportada no CSV (Unnamed: 0), descartou registros sem track_name, artists ou track_id e manteve apenas a primeira ocorrência de cada track_id.

3.1 Resultado da limpeza

Após o processamento, permaneceram 89.740 registros, correspondentes a 89.740 track_id únicos. Não restaram nomes de músicas ou artistas ausentes nem IDs duplicados. A remoção das repetições evitou que a mesma faixa tivesse influência repetida na formação dos grupos.

3.2 Tratamento das colunas textuais

As colunas track_name, artists, album_name e track_id foram preservadas para identificar as músicas e interpretar os resultados, mas não foram utilizadas como entradas do modelo. Esses campos são identificadores ou textos descritivos, e não medidas numéricas de similaridade acústica adequadas ao cálculo de distância do K-Means. A coluna track_genre também foi excluída para cumprir o requisito de formar grupos sem usar o gênero cadastrado. Assim, o modelo foi treinado com características sonoras numéricas e variáveis categóricas ligadas às propriedades musicais.

4. Análise de correlação acústica

Foi calculada a correlação de Pearson entre energy e acousticness após a limpeza dos dados. O coeficiente obtido foi −0,7326, indicando uma relação linear negativa forte no conjunto analisado. Em

termos práticos, faixas com maior energia tendem, nesta base, a apresentar menor valor de acousticness; por outro lado, faixas com maior acousticness tendem a apresentar menor energia. A relação não é perfeita e existem exceções. Além disso, correlação descreve associação e não demonstra causalidade.

5. Pré-processamento e modelagem

Foram utilizadas nove características numéricas: danceability, energy, acousticness, instrumentalness, liveness, speechiness, valence, tempo e loudness. Também foram utilizadas três características categóricas relacionadas à música: key, mode e time_signature. As variáveis numéricas foram padronizadas com StandardScaler, para evitar que escalas diferentes dominassem o cálculo das distâncias. As variáveis categóricas foram convertidas com OneHotEncoder. Após o pré-processamento, a matriz de entrada possuía 89.740 linhas e 28 atributos.

5.1 Algoritmo K-Means

Foi aplicado o algoritmo K-Means com n_clusters=5, random_state=42 e n_init=10. O número de clusters foi definido em cinco porque a atividade solicitava explicitamente cinco playlists ou “vibes”. O K-Means atribui cada música ao grupo cujo centroide fica mais próximo no espaço das características transformadas. Como se trata de aprendizado não supervisionado, os números dos clusters não representam categorias musicais predefinidas.

6. Resultados da clusterização

O algoritmo distribuiu as 89.740 músicas em cinco grupos de tamanhos diferentes. A distribuição e as médias das principais características ajudam a interpretar o perfil de cada grupo.

6.1 Quantidade de músicas por cluster

Cluster	Quantidade	Perfil médio resumido
0	33.712	Alta dançabilidade (0,693), energia elevada (0,730) e acousticness baixa (0,207).
1	26.822	Energia alta (0,821), acousticness muito baixa (0,068) e valence moderada-baixa (0,322).
2	7.335	Baixa energia (0,198), acousticness alta (0,822) e instrumentalness alta (0,776).
3	1.105	Speechiness muito alta (0,825) e liveness elevada (0,664).
4	20.766	Energia mais baixa (0,392), acousticness alta (0,667) e valence (0,404).

6.2 Perfil médio dos clusters

A tabela apresenta as médias calculadas pelo notebook para as nove características numéricas. Elas descrevem tendências de cada grupo, não rótulos definitivos de gênero musical.

Cluster	Danceability	Energy	Acousticness	Instrumentalness	Liveness	Speechiness	Valence	Tempo	Loudness
0	0,693	0,730	0,207	0,065	0,193	0,093	0,692	120,582	-6,543
1	0,476	0,821	0,068	0,239	0,264	0,084	0,322	136,180	-5,993
2	0,352	0,198	0,822	0,776	0,173	0,052	0,178	103,017	-20,699
3	0,573	0,674	0,729	0,008	0,664	0,825	0,449	101,795	-11,072
4	0,535	0,392	0,667	0,060	0,186	0,056	0,404	114,018	-10,465

7. Avaliação qualitativa do cluster 4

Para a avaliação qualitativa, foram selecionadas cinco músicas do cluster 4 com random_state=42. O cluster apresentou médias de energy=0,392, acousticness=0,667, danceability=0,535 e valence=0,404. Em conjunto, esses valores sugerem uma tendência a músicas com energia relativamente baixa e acousticness elevada, mas com variação no potencial de dança e na valência musical.

7.1 Músicas selecionadas

Música	Artista	Energy	Acousticness	Danceability	Valence
Payday	Crate Diggers	0,447	0,875	0,696	0,461
Rondine al nido - Live	Luciano Pavarotti; Andrea Griminelli; Orchestra…	0,345	0,974	0,240	0,173
Trettifyran	Per Myrberg	0,470	0,693	0,629	0,920
Someday You'll Call My Name	Hank Williams; Drifting Cowboys	0,240	0,955	0,527	0,400
Acaso Não Sabeis - Ao Vivo	Colo de Deus	0,555	0,685	0,358	0,277

7.2 Interpretação

As cinco faixas compartilham valores relativamente elevados de acousticness, o que é compatível com o perfil médio do cluster. Entretanto, não são completamente homogêneas: por exemplo, Rondine al nido - Live apresenta danceability e valence baixas, enquanto Trettifyran apresenta valence alta e danceability maior. Portanto, o grupo faz sentido parcialmente como uma playlist de tendência acústica, mas não necessariamente como uma playlist com humor, ritmo ou estilo uniforme. A avaliação baseada apenas em atributos e nomes não substitui a escuta das faixas.

8. Discussão e limitações

Os resultados mostram que características acústicas podem ser usadas para construir agrupamentos úteis como ponto de partida para playlists automáticas. A correlação negativa entre energy e acousticness também oferece uma interpretação intuitiva de parte da estrutura dos dados. Ainda assim, o K-Means depende das características selecionadas e da configuração do algoritmo. O uso de cinco clusters foi definido pela atividade, não por uma comparação sistemática de diferentes valores de K. Além disso, os grupos podem reunir músicas de gêneros ou contextos diferentes, pois track_genre foi intencionalmente excluída. Uma etapa futura poderia avaliar diferentes configurações, comparar métricas internas de clusterização e realizar uma avaliação auditiva com ouvintes.

9. Conclusão

O trabalho aplicou o K-Means a 89.740 músicas após a limpeza e o pré-processamento, gerando cinco clusters a partir de características musicais sem utilizar o gênero cadastrado. A correlação de Pearson entre energy e acousticness foi −0,7326, indicando associação linear negativa forte. A análise do cluster 4 mostrou coerência parcial: as faixas apresentaram acousticness relativamente alta em média, mas diferenças em energia, dançabilidade e valência. Conclui-se que a clusterização pode apoiar a criação de playlists automáticas, desde que os agrupamentos sejam interpretados e validados com critérios musicais e, idealmente, com avaliação humana.

Referências

PEDREGOSA, F. et al. Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, v. 12, p. 2825–2830, 2011.

SCIKIT-LEARN. KMeans. Documentação oficial. Disponível em: https://scikit-learn.org/stable/modules/generated/sklearn.cluster.KMeans.html. Acesso em: 19 out. 2026.

SCIKIT-LEARN. StandardScaler. Documentação oficial. Disponível em: https://scikit-learn.org/stable/modules/generated/sklearn.preprocessing.StandardScaler.html. Acesso em: 19 out. 2026.